

## Cours 5 - Le hasard s'en mêle...

Motivation : jeux finis à somme nulle :

considérons un jeu fini,  $S_1 = \{1, \dots, m\}$   
(ie  $T_1$  dispose de  $m$  stratégies numérotées  
 $1, \dots, m$ ),  $S_2 = \{1, \dots, n\}$ , de fonction  
de gain

$$g(i, j) = g_1(i, j) = -g_2(i, j) \\ = a_{ij} \in \mathbb{R}, i=1, \dots, m, \\ j=1, \dots, n;$$

le tableau du jeu sous forme normale  
fait donc intervenir la matrice

$$A = (a_{ij})_{i=1, m, j=1, n}, m \times n :$$

$T_2$		$j=1, n$		
$T_1$		...	$j$	...
	$\vdots$	$\ddots$	$\vdots$	$\ddots$
	$i$	...	$a_{ij}$	...
	$\vdots$	$\ddots$	$\vdots$	$\ddots$

On sait d'après le cours précédent qu'on a  
un équilibre mi :

$$\alpha = \max_{i=1, m} \min_{j=1, n} a_{ij} = \min_{j=1, n} \max_{i=1, m} a_{ij} = \beta$$

En général,  $\alpha \leq \beta$ , et on a deux cas :  
(sachant qu'il existe toujours  $\bar{i} \in \{1, \dots, m\}$  et  
 $\bar{j} \in \{1, \dots, n\}$  et  $\bar{t}$  :  $\left. \begin{aligned} \alpha &= \max_i \min_j a_{ij} = \min_j a_{\bar{i}j} \\ \beta &= \min_j \max_i a_{ij} = \max_i a_{i\bar{j}} \end{aligned} \right)$

i)  $\alpha = \beta$  : un équilibre existe,  $\alpha = a_{\bar{i}\bar{j}} = \beta$ , et aucune des deux joueuses n'a intérêt à jouer autrement que  $\bar{i}$  pour  $J_1$ ,  $\bar{j}$  pour  $J_2$ , même en connaissant la stratégie de l'autre ! C'est l'exemple du dilemme des traducteurs du cours précédent.

ii)  $\alpha < \beta$  : c'est par exemple le cas pour le jeu suivant :

$$A = \begin{bmatrix} 5 & 6 & 7 \\ 4 & 15 & 8 \\ 12 & 3 & 10 \end{bmatrix}$$

On voit que  $\bar{i} = 1$  (maximise le pire gain, c'est ici le seul), et que  $\bar{j} = 3$  (minimise le pire perte, c'est aussi le seul). On a

$$\alpha = 5 < a_{\bar{i}\bar{j}} = a_{13} = 7 < \beta = 10$$

de sorte qu'en jouant  $\bar{i}$  et  $\bar{j}$ , respectivement,  $J_1$  et  $J_2$  font tous les deux mieux que ce qu'ils pourraient espérer. Mais la tricherie devient désormais payante car, si  $J_1$  sait par exemple que  $J_2$  a joué  $\bar{j} = 3$ , elle a tout intérêt à jouer non pas  $\bar{i} = 1$ , mais  $i = 3$  (gain de 10). Au contraire si  $J_2$  anticipe que  $J_1$  va jouer  $i = 3$  (pour la raison précédente), elle a intérêt à jouer  $j = 2$  (perte de 3)...

En général donc, dans le cas où on a :

$$\alpha \leq a_{ij} \leq \beta$$

et l'une des deux inégalités au moins est stricte ; au moins l'une des deux joueuses fera strictement mieux que ce qu'elle espérait.

L'idée de John von Neumann, pour retrouver une situation d'équilibre consiste à jouer un grand nombre de parties en adoptant un pt de vue probabiliste :

- $J_1$  va jouer la stratégie  $i=1$  avec la proba  $y_1$ , la stratégie  $i=2$  avec la proba  $y_2$ ...
- de même  $J_2$  jouera la stratégie no.  $j \in \{1, \dots, m\}$  avec la proba  $x_j$ .

On parle alors de "stratégie mixte", et on voit que cela revient à agrandir  $\Sigma_1$  (resp.  $\Sigma_2$ ) en  $\Sigma_m := \{y \in \mathbb{R}^m \mid y \geq 0, y_1 + \dots + y_m = 1\}$  (resp.  $\Sigma_n := \{x \in \mathbb{R}^n \mid x \geq 0, x_1 + \dots + x_n = 1\}$ ).

Choisir une stratégie mixte  $y = (y_1, \dots, y_m) \in \Sigma_m$  revient donc à fixer avec quelle proba  $J_1$  jouera  $i=1$ , etc. Les stratégies précédentes,

### John von Neumann



John von Neumann dans les années 1940.

#### Biographie

Naissance	28 décembre 1903 Budapest (Autriche-Hongrie)
Décès	8 février 1957 (à 53 ans) Washington (États-Unis)
Sépulture	Princeton Cemetery ( <a href="#">en</a> )
Nom de naissance	Neumann János Lajos
Nationalité	<span><span></span></span> Hongrois <span><span></span></span> Américain (à partir de 1937)
Domicile	États-Unis
Formation	Université de Budapest École polytechnique de Zurich
Activités	Mathématicien, informaticien, chimiste, physicien, ingénieur, inventeur, économiste, physicien nucléaire, professeur d'université

dans  $\Sigma_1$  (resp.  $\Sigma_2$ ) on a "stratégies pures" consistent  
 donc à toujours jouer une stratégie  $i \in \{1, \dots, m\}$   
 (resp.  $j \in \{1, \dots, n\}$ ), il a la jouer avec la  
 proba  $y_i = 1$  :  $y = (0, \dots, 0, 1, 0, \dots, 0)$   
 (resp.  $x_j = 1$ , et  $x = (0, \dots, 0, 1, 0, \dots, 0)$ ).

Reste, pour mettre ce nouveau jeu (qui n'est  
 plus fini ! cf. card  $\Sigma_m = \text{card } \Sigma_n = \infty$  !) sous  
 forme normale à définir la fonction de  
 gain (on reste à somme nulle), ce que l'on  
 fait en considérant les gains moyens  
 (cf. Exo poker, T13, pour des considérations  
 analogues), en espérance :

tient donc  $(y, x) \in \Sigma_m \times \Sigma_n$ , on pose

$$\begin{aligned}
 g(y, x) &:= E(g(s^1, s^2)) && \text{indépendance } s^1 \text{ et } s^2 \\
 &= \sum_{i=1}^m \sum_{j=1}^n g(i, j) \cdot P(s^1=i) \cdot P(s^2=j) \\
 &= \sum_{i=1}^m \sum_{j=1}^n a_{ij} \cdot y_i \cdot x_j \\
 &= (A \cdot x \mid y)
 \end{aligned}$$

↑  
 Stratégie mixte  $T_1$   
 ↑  
 Stratégie mixte  $T_2$

où  $(\cdot \mid \cdot)$  est le produit scalaire sur  $\mathbb{R}^m$   
 $(y \mid z) = {}^t y \cdot z = \sum_{i=1}^m y_i \cdot z_i$ . Dans ce calcul  
 d'espérance, on a considéré  $s^1$  et  $s^2$   
 (stratégies de  $T_1$  et  $T_2$ , resp.) comme des v.a.  
 (= variables aléatoires) discrètes à valeurs dans



$S_1 = \{1, \dots, m\}$  et  $S_2 = \{1, \dots, n\}$ , rapp., de densités respectives  $y = (y_1, \dots, y_m)$  et  $x = (x_1, \dots, x_n)$ . (C'est des probas, on a bien  $\sum_i y_i = \sum_j x_j = 1$ .)

Remarque: si  $k \geq 1$ , l'ensemble

$$\Sigma_k := \{x \in \mathbb{R}^k \mid x_1 \geq 0, \dots, x_k \geq 0, x_1 + \dots + x_k = 1\}$$

s'appelle le simplexe unité de  $\mathbb{R}^k$ . C'est un ensemble compact (= fermé borné) et convexe.

Ex.  $\Sigma_1 = \{1\}$



Les sommets (=  $(1,0,0)$ ,  $(0,1,0)$  et  $(0,0,1)$  si  $k=3$ ) de  $\Sigma_k$  correspondent aux stratégies pures (1, 2 ou 3, si  $k=3$ ).

D'après le cours précédent, trouver un équilibre pour ce nouveau jeu (à somme nulle) dont les stratégies sont désormais étendues à  $\Sigma_m \times \Sigma_n$ , est équivalent à trouver un pt selle, c'est à dire un couple de stratégies  $(\bar{y}, \bar{x}) \in \Sigma_m \times \Sigma_n$  tq :

$$\sup_{y \in \Sigma_m} \inf_{x \in \Sigma_n} (Ax|y) = (A\bar{x}|\bar{y}) = \inf_{x \in \Sigma_n} \sup_{y \in \Sigma_m} (Ax|y)$$

$g(\bar{y}, \bar{x})$

Th. (John von Neumann): un jeu fini admet un équilibre en stratégies mixtes. Autrement dit, soit  $A$  une matrice  $m \times n$ , il existe un point selle  $(\bar{y}, \bar{x}) \in \Sigma_m \times \Sigma_n$  tq

$$\sup_{y \in \Sigma_m} \inf_{x \in \Sigma_n} (Ax | y) = \underbrace{(A\bar{x} | \bar{y})}_{v} = \inf_{x \in \Sigma_n} \sup_{y \in \Sigma_m} (Ax | y).$$

De plus, si la valeur  $v$  du jeu est  $> 0$ , les pts-selles  $(\bar{y}, \bar{x}) \in \Sigma_m \times \Sigma_n$  sont caractérisés par le fait qu'ils sont solutions des problèmes d'optimisation suivants :

$$\begin{aligned} \text{i) } \bar{x} \text{ solution de } & \begin{cases} (1_m | x) \rightarrow \max \\ Ax \leq 1_m \\ x \geq 0 \end{cases} & \begin{aligned} 1_m &= (1, \dots, 1) \in \mathbb{R}^m \\ 1_m &= (1, \dots, 1) \in \mathbb{R}^m \end{aligned} \\ \text{ii) } \bar{y} \text{ solution de } & \begin{cases} (1_m | y) \rightarrow \min \\ A^T y \geq 1_m \\ y \geq 0 \end{cases} \end{aligned}$$

Remarque: les problèmes i) et ii) sont des problèmes de programmation linéaire (LP = "Linear Programming") qui forment une classe de problèmes d'optimisation pour lesquels on dispose d'algorithmes de résolution efficaces, y compris en grande taille ( $m$  et  $n$  grands). Les éléments de preuve qui suivent utilisent ce point de vue.

dém.: soit  $A$  une matrice  $m \times n$ ; soit  $\bar{a}$   
 remplacer  $A$  par  $A + \|A\|_\infty + 1$  (i.e. faire  
 $a_{ij} \leftarrow a_{ij} + \max_{i,j} |a_{ij}| + 1$ ) on est sûr que tous

les coeffts sont  $> 0$  de sorte que  $0 < \alpha \leq \beta$ .  
 Comme transporter les valeurs des gains d'une  
 même cte ne change pas les éventuelles  
 stratégies à l'équilibre, on supposera donc  
 qu'on a  $0 < \alpha \leq \beta$ . Soit alors  $t > 0$ , on a :

$$t \geq \beta = \inf_{x \in \Sigma_m} \sup_{y \in \Sigma_m} (Ax | y) \\
= \min_{x \in \Sigma_m} \max_{y \in \Sigma_m} (Ax | y) \quad (\text{cf. Compacité de } \Sigma_m \text{ et } \Sigma_m)$$

$$\Leftrightarrow (\exists x \in \Sigma_m) : \max_{y \in \Sigma_m} (Ax | y) \leq t \\
= \text{la plus grande coordonnée du vecteur } Ax \in \mathbb{R}^m \text{ (évident!)}$$

$$\Leftrightarrow (\exists x \in \Sigma_m) : Ax \leq t \cdot 1_m$$

$$\Leftrightarrow (\exists x \geq 0) : (1_m | x) = 1 \text{ et } Ax \leq t \cdot 1_m$$

$$\Leftrightarrow (\exists x \geq 0) : Ax \leq 1_m \text{ et } (1_m | x) = 1/t \quad (*)$$

$$\Leftrightarrow 1/t \leq \max \{ (1_m | x) \text{ avec } x \geq 0 \text{ et } Ax \leq 1_m \}$$

$$\text{Donc, } \frac{1}{t} \leq \frac{1}{\beta} \Leftrightarrow \frac{1}{t} \leq \max \{ (1_m | x) \mid Ax \leq 1_m, x \geq 0 \}$$

$$\text{ie } \frac{1}{\beta} = \max \{ (1_m | x) \mid Ax \leq 1_m, x \geq 0 \}.$$

On, le lagrangien du problème d'optimisation

$$i) \begin{cases} (1_m | x) \rightarrow \max \\ Ax \leq 1_m \\ x \geq 0 \end{cases} \Leftrightarrow \begin{cases} (1_m | x) \rightarrow \min \\ (Ax - 1_m \leq 0) \\ -x \leq 0 \end{cases}$$

Avec contraintes inégalités s'écrit

$$L(x, y, \mu) = -(1_m | x) + (\mu | -x) + (y | Ax - 1_m).$$

Le problème i) est équivalent à

$$\inf_{x \in \mathbb{R}^n} \sup_{\substack{y \geq 0 \\ \mu \geq 0}} L(x, y, \mu) \quad (\text{évident}),$$

qui - même équivalent par dualité (puisque le problème est linéaire donc convexe...) à

$$\sup_{\substack{y \geq 0 \\ \mu \geq 0}} \inf_{x \in \mathbb{R}^n} L(x, y, \mu) \\ = -(1_m | y) \text{ si } \nabla_x L = 0, \\ \text{c'est-à-dire } -1_m - \mu + {}^t A y = 0$$

$$\begin{aligned} (=) \quad & \sup_{\substack{y \geq 0 \\ \mu \geq 0 \\ {}^t A y = 1_m + \mu}} -(1_m | y) \end{aligned}$$

$$\begin{aligned} (=) \quad & \left\{ \begin{array}{l} (1_m | y) \rightarrow \min : \textcircled{\text{ii}} \\ {}^t A y \geq 1_m \\ y \geq 0 \end{array} \right. \end{aligned}$$

On montre de même que pour i) que la valeur de ii) est  $1/2$ ,

d'où  $\frac{1}{2} = \frac{1}{\beta}$ , d'où l'existence de pts-selles


et leur caractérisation à l'aide de i) et ii).

\* On a remplacé  $x$  par  $\frac{x}{\epsilon}$ , d'où  $\frac{\bar{x}}{\epsilon}$  et  $\frac{\bar{y}}{\epsilon}$ .  $\square$



Pour aller plus loin :  
 les jeux comme les échecs ou le go possèdent un nombre d'états trop grand pour qu'on leur applique directement ce type d'analyse. On utilise plutôt des méthodes de Machine Learning (apprentissage par renforcement, notamment) basées sur le même type d'utils mathématiques (optimisation, statistique, graphes...)

Le programme AlphaZero développé par DeepMind est actuellement capable de battre n'importe quel joueur humain aux échecs ou au go.



A general reinforcement learning algorithm that masters chess, shogi, and Go through self-play

David Silver<sup>1,2,\*</sup>, Thomas Hubert<sup>1,\*</sup>, Julian Schrittwieser<sup>1,\*</sup>, Ioannis Antonoglou<sup>1</sup>, Matthew Lai<sup>1</sup>, Arthur Guez<sup>1</sup>, M...

Science 07 Dec 2018:  
 Vol. 362, Issue 6419, pp. 1140-1144  
 DOI: 10.1126/science.aar6404